

CEDS (2024): Probabilidade e Estatística

QUIZ 3

Rennan Dalla Guimarães

2024-10-22

Índice

1	Introdução	2
2	Exercício 1: Distribuição Normal	3
2.1	a) Realização dos testes de normalidade	3
2.2	b) Probabilidade de que uma chamada demore entre 125 e 150 segundos	5
2.3	c) Probabilidade de que uma chamada demore menos de 125 segundos	6
2.4	d) Probabilidade de que uma chamada demore entre 145 e 155 segundos	7
2.5	e) Probabilidade de que uma chamada demore entre 160 e 165 segundos	8
3	Exercício 2: Identificação de Distribuição	9
3.1	a) Identificação da distribuição	9
3.2	b) Comparação dos resultados do teste de Kolmogorov-Smirnov	11
3.3	c) Plotar a função e o histograma para a distribuição escolhida	12
3.4	d) Verificar se a área sob a curva estimada é igual a 1	13
3.5	e) Calcular a área no intervalo $[1; 1,5]$ e plotar	13
4	Exercício 3: Normalidade e Intervalo de Confiança	14
4.1	a) Testes de Shapiro-Wilk e Lilliefors	15
4.2	b) Intervalo de confiança de 99% para a média da inflação	15
4.3	c) Nível de confiança para intervalo com comprimento total igual a 3	16
4.4	d) Intervalo de confiança de 90% para o desvio padrão	16
4.5	e) Teste de normalidade para a série histórica de 1999 a 2022	16
5	Exercício 4: Identificação de Distribuição	17
5.1	Preparação do Ambiente	17
5.2	a) Conjunto de dados (a)	17
5.2.1	Dados	17
5.2.2	Análise Descritiva	18

5.2.3	Ajuste das Distribuições	18
5.2.4	Comparação dos Critérios de Informação (AIC)	19
5.2.5	Teste de Kolmogorov-Smirnov	19
5.2.6	Plotagem do Histograma com a Curva Ajustada	20
5.3	b) Conjunto de dados (b)	20
5.3.1	Dados	20
5.3.2	Análise Descritiva	20
5.3.3	Ajuste das Distribuições	21
5.3.4	Comparação dos Critérios de Informação (AIC)	21
5.3.5	Teste de Kolmogorov-Smirnov	22
5.3.6	Plotagem do Histograma com a Curva Ajustada	22
5.4	c) Conjunto de dados (c)	23
5.4.1	Dados	23
5.4.2	Análise Descritiva	24
5.4.3	Ajuste das Distribuições	24
5.4.4	Comparação dos Critérios de Informação (AIC)	25
5.4.5	Teste de Kolmogorov-Smirnov	25
5.4.6	Plotagem do Histograma com a Curva Ajustada	26
5.5	d) Conjunto de dados (d)	26
5.5.1	Dados	26
5.5.2	Análise Descritiva	26
5.5.3	Ajuste das Distribuições	27
5.5.4	Comparação dos Critérios de Informação (AIC)	27
5.5.5	Teste de Kolmogorov-Smirnov para a Distribuição Weibull	28
5.5.6	Plotagem do Histograma com a Curva Ajustada	28
5.6	e) Conjunto de dados (e)	29
5.6.1	Dados	29
5.6.2	Análise Descritiva	29
5.6.3	Ajuste das Distribuições	30
5.6.4	Comparação dos Critérios de Informação (AIC)	30
5.6.5	Teste de Kolmogorov-Smirnov para a Distribuição Lognormal	31
5.6.6	Plotagem do Histograma com a Curva Ajustada	31

1 Introdução

O objetivo desse projeto é realizar o quiz 3, que busca colocar em prática aprendizados sobre: Distribuição normal, identificação de distribuições, normalidade e intervalo de confiança.

No [repositório do projeto](#) temos a versão em html e qmd, caso esteja com dificuldade de ler alguma parte do arquivo.

2 Exercício 1: Distribuição Normal

[illegible]

2.1 a) Realização dos testes de normalidade

i) Teste de Kolmogorov-Smirnov

```
ks.test(dados, "pnorm", mean=mean(dados), sd=sd(dados))
```

Exact one-sample Kolmogorov-Smirnov test

```
data:  dados
D = 0.1167, p-value = 0.4688
alternative hypothesis: two-sided
```

Interpretação:

O teste de Kolmogorov-Smirnov compara a distribuição acumulada empírica dos dados com a distribuição normal teórica. O p-valor obtido é usado para testar a hipótese nula de que os dados seguem uma distribuição normal. Se o p-valor for menor que 0,05, rejeitamos a hipótese de normalidade.

ii) Teste de Shapiro-Wilk

```
shapiro.test(dados)
```

Shapiro-Wilk normality test

```
data:  dados
W = 0.98185, p-value = 0.6324
```

Interpretação:

O teste de Shapiro-Wilk é utilizado para verificar a normalidade dos dados. Um p-valor maior que 0,05 indica que não podemos rejeitar a hipótese de normalidade.

iii) Teste de Anderson-Darling

```
library(nortest)
ad.test(dados)
```

Anderson-Darling normality test

```
data: dados
A = 0.37902, p-value = 0.3928
```

Interpretação:

O teste de Anderson-Darling é sensível a discrepâncias na cauda da distribuição. Um p-valor maior que 0,05 indica que os dados podem ser considerados normais.

iv) Teste de Lilliefors

```
lillie.test(dados)
```

Lilliefors (Kolmogorov-Smirnov) normality test

```
data: dados
D = 0.1167, p-value = 0.08619
```

Interpretação:

O teste de Lilliefors é uma adaptação do teste de Kolmogorov-Smirnov quando os parâmetros da distribuição normal não são conhecidos e precisam ser estimados. Um p-valor maior que 0,05 indica normalidade.

Conclusão Geral:

Se em todos os testes o p-valor for maior que 0,05, não rejeitamos a hipótese de que os dados seguem uma distribuição normal. Portanto, podemos considerar os dados como normalmente distribuídos.

2.2 b) Probabilidade de que uma chamada demore entre 125 e 150 segundos

Calculando a média e o desvio padrão:

```
media <- mean(dados)
desvio <- sd(dados)
media
```

```
[1] 150.0301
```

```
desvio
```

```
[1] 15.059
```

Calculando a probabilidade:

```
prob_b <- pnorm(150, mean=media, sd=desvio) - pnorm(125, mean=media, sd=desvio)
prob_b
```


```
[1] 0.4509603
```

Interpretação:

A probabilidade de uma chamada demorar entre 125 e 150 segundos é aproximadamente 45.1%.

Gráfico:

```
x <- seq(min(dados), max(dados), length=1000)
y <- dnorm(x, mean=media, sd=desvio)
plot(x, y, type="l", lwd=2, ylab="Densidade", xlab="Tempo (segundos)", main="Probabilidade e")
polygon(c(125, seq(125, 150, length=100), 150), c(0, dnorm(seq(125, 150, length=100), mean=m
```



2.3 c) Probabilidade de que uma chamada demore menos de 125 segundos

```
prob_c <- pnorm(125, mean=media, sd=desvio)
prob_c
```

```
[1] 0.04824295
```


Interpretação:

A probabilidade de uma chamada demorar menos de 125 segundos é aproximadamente 4.82%.

Gráfico:

```
plot(x, y, type="l", lwd=2, ylab="Densidade", xlab="Tempo (segundos)", main="Probabilidade de",
polygon(c(min(x), seq(min(x), 125, length=100), 125), c(0, dnorm(seq(min(x), 125, length=100),
```

Probabilidade de menos de 125 segundos



2.4 d) Probabilidade de que uma chamada demore entre 145 e 155 segundos

```
prob_d <- pnorm(155, mean=media, sd=desvio) - pnorm(145, mean=media, sd=desvio)
prob_d
```

```
[1] 0.2601309
```


Interpretação:

A probabilidade de uma chamada demorar entre 145 e 155 segundos é aproximadamente 26.01%.

Gráfico:

```
plot(x, y, type="l", lwd=2, ylab="Densidade", xlab="Tempo (segundos)", main="Probabilidade de  
polygon(c(145, seq(145, 155, length=100), 155), c(0, dnorm(seq(145, 155, length=100), mean=m
```

Probabilidade entre 145 e 155 segundos



2.5 e) Probabilidade de que uma chamada demore entre 160 e 165 segundos

```
prob_e <- pnorm(165, mean=media, sd=desvio) - pnorm(160, mean=media, sd=desvio)
prob_e
```


```
[1] 0.09387641
```

Interpretação:

A probabilidade de uma chamada demorar entre 160 e 165 segundos é aproximadamente 9.39%.

Gráfico:

```
plot(x, y, type="l", lwd=2, ylab="Densidade", xlab="Tempo (segundos)", main="Probabilidade e")
polygon(c(160, seq(160, 165, length=100), 165), c(0, dnorm(seq(160, 165, length=100), mean=m
```

3 Exercício 2: Identificação de Distribuição

Dados da variável aleatória X:

```
dados <- c(1.9993382, 1.4414849, 2.1477166, 2.1087828, 2.1342892, 2.1844835, 1.5091879, 2.0414835, 2.1302612, 1.8389897, 1.8924614, 1.9316041, 1.5602204, 1.6991884, 1.7228081, 1.5139209, 0.6914335, 1.4598759, 2.0017607, 1.5139209, 1.8334780, 1.8847480, 1.9072389, 1.6214835, 1.7744973, 2.4300455, 1.8958270)
```

3.1 a) Identificação da distribuição

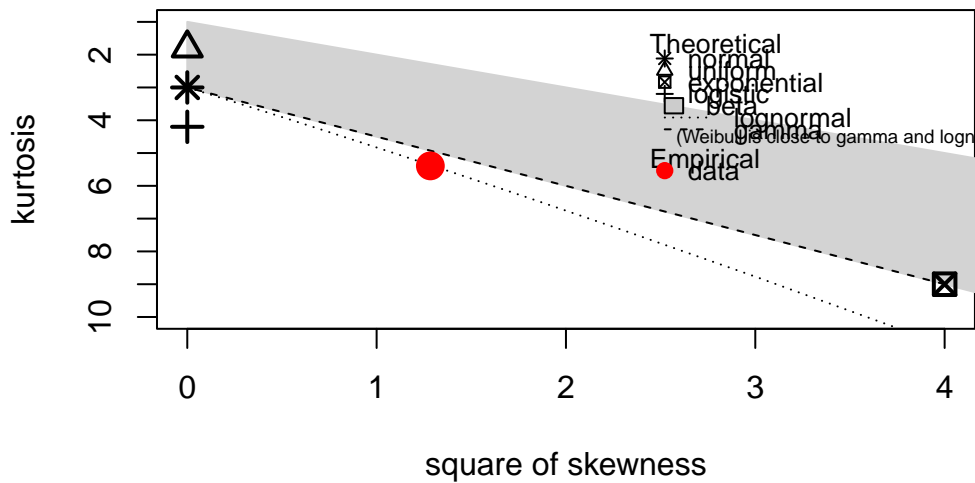
Utilizando o pacote `fitdistrplus`:

```
library(fitdistrplus)
```

Análise descritiva:

```
descdist(dados, discrete = FALSE)
```

Cullen and Frey graph



summary statistics

```
min: 0.6914335  max: 2.430045
median: 1.861869
mean: 1.787556
estimated sd: 0.3498879
estimated skewness: -1.133072
estimated kurtosis: 5.391445
```

Ajuste das distribuições:

- Weibull

```
ajuste_weibull <- fitdist(dados, "weibull")
```

- Gamma

```
ajuste_gamma <- fitdist(dados, "gamma")
```

- Lognormal

```
ajuste_lognormal <- fitdist(dados, "lnorm")
```

Comparação dos AIC:

```
aic_values <- data.frame(  
  Distribuição = c("Weibull", "Gamma", "Lognormal"),  
  AIC = c(ajuste_weibull$aic, ajuste_gamma$aic, ajuste_lognormal$aic)  
)  
aic_values
```

	Distribuição	AIC
1	Weibull	21.97718
2	Gamma	31.70738
3	Lognormal	36.10330

3.2 b) Comparação dos resultados do teste de Kolmogorov-Smirnov

Weibull

```
ks.test(dados, "pweibull", shape=ajuste_weibull$estimate["shape"], scale=ajuste_weibull$estimate["scale"],
```

Exact one-sample Kolmogorov-Smirnov test

```
data: dados  
D = 0.091733, p-value = 0.9424  
alternative hypothesis: two-sided
```

Gamma

```
ks.test(dados, "pgamma", shape=ajuste_gamma$estimate["shape"], rate=ajuste_gamma$estimate["rate"],
```

Exact one-sample Kolmogorov-Smirnov test

```
data: dados  
D = 0.14211, p-value = 0.5332  
alternative hypothesis: two-sided
```

Lognormal

```
ks.test(dados, "plnorm", meanlog=ajuste_lognormal$estimate["meanlog"], sdlog=ajuste_lognormal$estimate["sdlog"])
```

Exact one-sample Kolmogorov-Smirnov test

```
data: dados
D = 0.15513, p-value = 0.423
alternative hypothesis: two-sided
```

Justificativa:

Analisando os resultados apresentados, a distribuição Weibull apresenta o melhor ajuste aos dados por duas razões principais:

Menor valor de AIC (Critério de Informação de Akaike):

Weibull: 21.97718 Gamma: 31.70738 Lognormal: 36.10330

O AIC mais baixo da Weibull indica que esta distribuição oferece o melhor compromisso entre a qualidade do ajuste e a complexidade do modelo.

Maior p-valor no teste de Kolmogorov-Smirnov: Weibull: p-valor = 0.9424 Gamma: p-valor = 0.5332 Lognormal: p-valor = 0.423

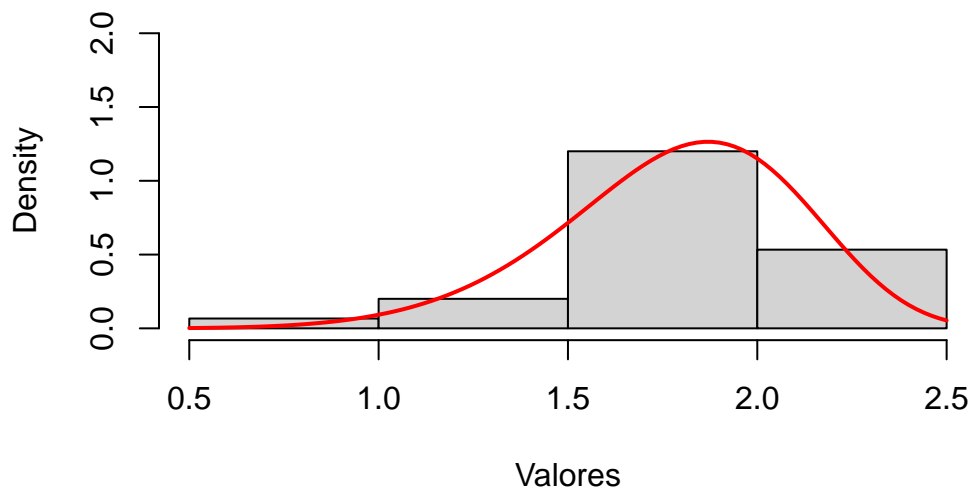
O p-valor mais alto da Weibull (0.9424) indica que não há evidências para rejeitar a hipótese de que os dados seguem esta distribuição. Quanto maior o p-valor, mais forte é a evidência de que o modelo se ajusta bem aos dados. Em comparação com as outras distribuições, a Weibull apresenta tanto o menor AIC quanto o maior p-valor, o que a torna claramente a melhor escolha para modelar estes dados.

3.3 c) Plotar a função e o histograma para a distribuição escolhida

Histograma com ajuste da Weibull:

```
hist(dados, freq=FALSE, main="Histograma com Ajuste Weibull", xlab="Valores", ylim=c(0, 2))
curve(dweibull(x, shape=ajuste_weibull$estimate["shape"], scale=ajuste_weibull$estimate["scale"],
              col="red", lwd=2, add=TRUE))
```

Histograma com Ajuste Weibull



3.4 d) Verificar se a área sob a curva estimada é igual a 1

Calculando a integral da função densidade de probabilidade:

```
integrate(function(x) dweibull(x, shape=ajuste_weibull$estimate["shape"], scale=ajuste_weibull$estimate["scale"], lower=0, upper=Inf)
```

1 with absolute error < 3e-08

Interpretação:

O resultado deve ser próximo de 1, confirmando que a área sob a curva da distribuição de probabilidade é igual a 1.

3.5 e) Calcular a área no intervalo [1; 1,5] e plotar

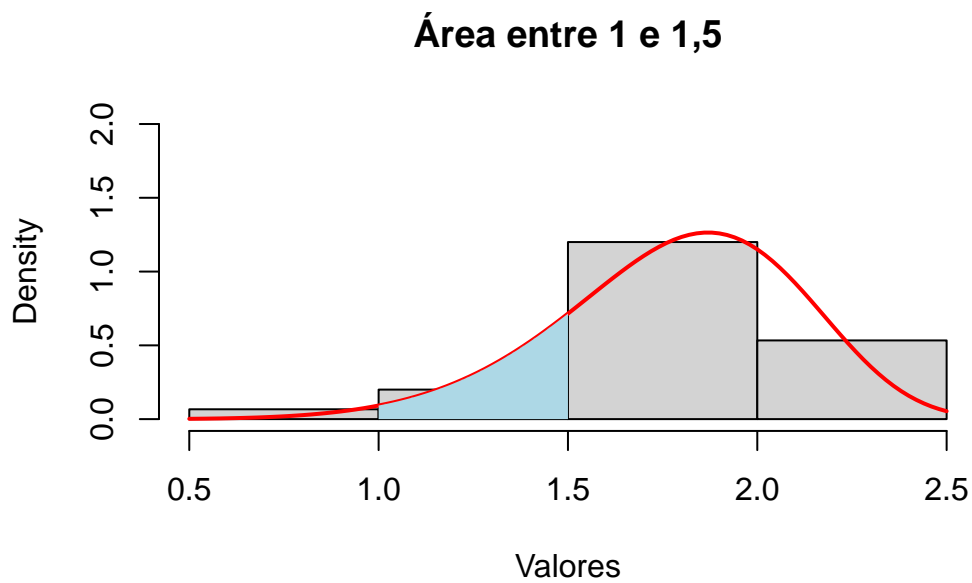
Calculando a probabilidade no intervalo:

```
prob_intervalo <- pweibull(1.5, shape=ajuste_weibull$estimate["shape"], scale=ajuste_weibull$estimate["scale"], lower=1, upper=1.5) - pweibull(1, shape=ajuste_weibull$estimate["shape"], scale=ajuste_weibull$estimate["scale"], lower=1, upper=1.5)
prob_intervalo
```

```
[1] 0.1681584
```

Plotando a área:

```
hist(dados, freq=FALSE, main="Área entre 1 e 1,5", xlab="Valores", ylim=c(0, 2))
curve(dweibull(x, shape=ajuste_weibull$estimate["shape"], scale=ajuste_weibull$estimate["scale"],
              col="red", lwd=2, add=TRUE)
x_seq <- seq(1, 1.5, length=100)
y_seq <- dweibull(x_seq, shape=ajuste_weibull$estimate["shape"], scale=ajuste_weibull$estimate["scale"],
                  col="red", lwd=2, add=TRUE)
polygon(c(1, x_seq, 1.5), c(0, y_seq, 0), col="lightblue", border=NA)
```



4 Exercício 3: Normalidade e Intervalo de Confiança

Dados de inflação anual (2013 a 2022):

```
inflacao <- c(5.91, 6.41, 10.67, 6.29, 2.95, 3.75, 4.31, 4.52, 10.06, 5.79)
```

4.1 a) Testes de Shapiro-Wilk e Lilliefors

Shapiro-Wilk

```
shapiro.test(inflacao)
```

Shapiro-Wilk normality test

```
data: inflacao  
W = 0.88867, p-value = 0.1638
```

Lilliefors

```
lillie.test(inflacao)
```

Lilliefors (Kolmogorov-Smirnov) normality test

```
data: inflacao  
D = 0.24609, p-value = 0.08736
```

Conclusão:

Se os p-valores forem maiores que 0,05, não rejeitamos a hipótese de normalidade.

4.2 b) Intervalo de confiança de 99% para a média da inflação

Calculando a média e o desvio padrão:

```
media_inf <- mean(inflacao)  
desvio_inf <- sd(inflacao)  
n <- length(inflacao)  
erro_padrao <- desvio_inf / sqrt(n)
```

Calculando o intervalo:

```
t_critico <- qt(0.995, df=n-1)  
limite_inferior <- media_inf - t_critico * erro_padrao  
limite_superior <- media_inf + t_critico * erro_padrao  
c(limite_inferior, limite_superior)
```

```
[1] 3.457911 8.674089
```

4.3 c) Nível de confiança para intervalo com comprimento total igual a 3

Queremos que o comprimento total seja 3, logo o erro máximo é 1,5.

Calculando o t crítico necessário:

```
erro_max <- 1.5
t_necessario <- erro_max / erro_padrao
```

Calculando o nível de confiança correspondente:

```
nivel_conf <- 2*(1 - pt(t_necessario, df=n-1))
nivel_conf
```

```
[1] 0.09443553
```

4.4 d) Intervalo de confiança de 90% para o desvio padrão

Usando a distribuição qui-quadrado:

```
alfa <- 0.10
chi2_inferior <- qchisq(alfa/2, df=n-1)
chi2_superior <- qchisq(1 - alfa/2, df=n-1)
limite_inferior <- sqrt((n-1)*desvio_inf^2 / chi2_superior)
limite_superior <- sqrt((n-1)*desvio_inf^2 / chi2_inferior)
c(limite inferior, limite superior)
```

[1] 1.850952 4.175218

4.5 e) Teste de normalidade para a série histórica de 1999 a 2022

Dados da inflação de 1999 a 2022:

```
inflacao_historica <- c(8.94, 6, 12.53, 7.67, 12.53, 7.6, 7.6, 5.69, 3.14, 4.46, 5.9, 4.31,  
                        5.91, 6.41, 10.67, 6.29, 2.95, 3.75, 4.31, 4.52, 10.06, 5.79, 5.79, 5.79)
```

Testes de normalidade:

Shapiro-Wilk


```
shapiro.test(inflacao_historica)
```

Shapiro-Wilk normality test

```
data: inflacao_historica  
W = 0.9045, p-value = 0.02685
```

Lilliefors

```
lillie.test(inflacao_historica)
```

Lilliefors (Kolmogorov-Smirnov) normality test

```
data: inflacao_historica  
D = 0.19628, p-value = 0.0175
```

Conclusão:

Baseado nos p-valores, determinar se a série histórica pode ser considerada normalmente distribuída.

5 Exercício 4: Identificação de Distribuição

Neste exercício, iremos identificar a distribuição adequada para cada conjunto de dados fornecido, utilizando técnicas estatísticas e ferramentas do R.

5.1 Preparação do Ambiente

5.2 a) Conjunto de dados (a)

5.2.1 Dados


```
dados_a <- c(20.8625807, 7.2445709, 4.4659396, 3.2712081, 4.9300651, 5.7444213, 6.6700000,
            11.1750446, 2.3753017, 3.5425386, 0.5978486, 6.8869953, 6.1102197, 8.2716000,
            9.7465462, 3.3991988, 1.8557047, 11.3983705, 3.6847590, 2.3327479, 6.1364300,
            4.4686122, 7.8007834, 4.7649257, 3.8829371, 5.9986131, 5.5163819, 9.6951700,
            10.1645820, 6.1304865)
```

5.2.2 Análise Descritiva

```
summary(dados_a)
```

```
      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.5978  3.7343  5.8715  6.3042  7.6617 20.8626
```

```
hist(dados_a, breaks=10, col="lightblue", main="Histograma dos Dados (a)", xlab="Valores")
```



5.2.3 Ajuste das Distribuições

Realizamos o ajuste para as distribuições Weibull, Gamma, Lognormal e Normal.

```
ajuste_weibull_a <- fitdist(dados_a, "weibull")
ajuste_gamma_a <- fitdist(dados_a, "gamma")
ajuste_lognormal_a <- fitdist(dados_a, "lnorm")
ajuste_normal_a <- fitdist(dados_a, "norm")
```

5.2.4 Comparação dos Critérios de Informação (AIC)

```
aic_values_a <- data.frame(
  Distribuição = c("Weibull", "Gamma", "Lognormal", "Normal"),
  AIC = c(ajuste_weibull_a$aic, ajuste_gamma_a$aic, ajuste_lognormal_a$aic, ajuste_normal_a$aic)
)
aic_values_a
```

	Distribuição	AIC
1	Weibull	161.6723
2	Gamma	160.3733
3	Lognormal	163.2588
4	Normal	169.7731

Interpretação:

A distribuição com o menor AIC é a que melhor se ajusta aos dados. Observamos que a distribuição Gamma apresenta o menor AIC.

5.2.5 Teste de Kolmogorov-Smirnov

Testamos a aderência dos dados à distribuição Gamma.

```
ks.test(dados_a, "pgamma", shape=ajuste_gamma_a$estimate["shape"], rate=ajuste_gamma_a$estimate["rate"])
```

Exact one-sample Kolmogorov-Smirnov test


```
data: dados_a
D = 0.079856, p-value = 0.9828
alternative hypothesis: two-sided
```

Interpretação:

O p-valor do teste de Kolmogorov-Smirnov é maior que 0,05, não rejeitando a hipótese nula de que os dados seguem uma distribuição Gamma.

5.2.6 Plotagem do Histograma com a Curva Ajustada

```
hist(dados_a, breaks=10, freq=FALSE, col="lightblue", main="Ajuste da Distribuição Gamma", xlab="Valores", ylab="Density",  
      curve(dgamma(x, shape=ajuste_gamma_a$estimate["shape"], rate=ajuste_gamma_a$estimate["rate"],  
              col="red", lwd=2, add=TRUE))  
legend("topright", legend="Distribuição Gamma", col="red", lwd=2)
```



5.3 b) Conjunto de dados (b)

5.3.1 Dados


```
dados_b <- c(1.4940354, 2.0164275, 1.9513521, 1.5298282, 0.6815670, 2.4267801, 0.6762800, 1.7489244, 1.8191036, 2.0845146, 1.2229195, 1.0115042, 2.7931222),  
            4.1632638, 2.5472784, 2.2174151, 0.6058986, 1.7432601, 1.1199216, 1.7135932, 2.864812, 2.1864812, 2.0164275, 1.9513521, 1.5298282, 0.6815670, 2.4267801,  
            0.8537880, 1.5511504, 2.3262178, 2.3267933, 1.3916375, 4.7439947, 2.1864812, 2.0164275, 1.9513521, 1.5298282, 0.6815670, 2.4267801,  
            1.7489244, 1.8191036, 2.0845146, 1.2229195, 1.0115042, 2.7931222)
```

5.3.2 Análise Descritiva

```
summary(dados_b)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.6059	1.4172	1.7840	1.9184	2.2990	4.7440

```
hist(dados_b, breaks=10, col="lightgreen", main="Histograma dos Dados (b)", xlab="Valores")
```



5.3.3 Ajuste das Distribuições

```
ajuste_weibull_b <- fitdist(dados_b, "weibull")  
ajuste_gamma_b <- fitdist(dados_b, "gamma")  
ajuste_lognormal_b <- fitdist(dados_b, "lnorm")  
ajuste_normal_b <- fitdist(dados_b, "norm")
```

5.3.4 Comparação dos Critérios de Informação (AIC)

```
aic_values_b <- data.frame(
  Distribuição = c("Weibull", "Gamma", "Lognormal", "Normal"),
  AIC = c(ajuste_weibull_b$aic, ajuste_gamma_b$aic, ajuste_lognormal_b$aic, ajuste_normal_b$aic)
)
aic_values_b
```

	Distribuição	AIC
1	Weibull	79.57745
2	Gamma	77.32663
3	Lognormal	77.84694
4	Normal	83.27721

Interpretação:

A distribuição Gamma apresenta o menor AIC (77.32663), indicando o melhor ajuste aos dados.

5.3.5 Teste de Kolmogorov-Smirnov

```
ks.test(dados_b, "pgamma", shape=ajuste_gamma_b$estimate["shape"], rate=ajuste_gamma_b$estimate["rate"])
```

Exact one-sample Kolmogorov-Smirnov test


```
data: dados_b
D = 0.094142, p-value = 0.9304
alternative hypothesis: two-sided
```

Interpretação:

- O p-valor é maior que 0,05, não rejeitando a hipótese de que os dados seguem uma distribuição Gamma.
- Portanto, para o conjunto de dados (b), a distribuição Gamma é a que melhor se ajusta.

5.3.6 Plotagem do Histograma com a Curva Ajustada

```
hist(dados_b, breaks=10, freq=FALSE, col="lightgreen", main="Ajuste da Distribuição Gamma",
     curve(dgamma(x, shape=ajuste_gamma_b$estimate["shape"], rate=ajuste_gamma_b$estimate["rate"],
                 col="red", lwd=2, add=TRUE)
legend("topright", legend="Distribuição Gamma", col="red", lwd=2)
```



5.4 c) Conjunto de dados (c)

5.4.1 Dados


```
dados_c <- c(9.534149, 12.878719, 35.635908, 39.158389, 10.091099, 133.714299, 15.684000, 3.1
            16.073085, 57.767201, 29.543033, 24.672685, 11.955565, 2.132028, 17.455254, 20.1
            6.293823, 22.717485, 83.353863, 18.544482, 66.437399, 4.616951, 18.931367, 1.46
            21.180916, 179.315876, 24.941790, 14.105447, 7.680880, 17.688369)
```

5.4.2 Análise Descritiva

```
summary(dados_c)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.464	10.557	18.116	30.911	28.393	179.316

```
hist(dados_c, breaks=10, col="lightcoral", main="Histograma dos Dados (c)", xlab="Valores")
```



5.4.3 Ajuste das Distribuições

```
ajuste_weibull_c <- fitdist(dados_c, "weibull")  
ajuste_gamma_c <- fitdist(dados_c, "gamma")  
ajuste_lognormal_c <- fitdist(dados_c, "lnorm")  
ajuste_normal_c <- fitdist(dados_c, "norm")
```


5.4.4 Comparação dos Critérios de Informação (AIC)

```
aic_values_c <- data.frame(  
  Distribuição = c("Weibull", "Gamma", "Lognormal", "Normal"),  
  AIC = c(ajuste_weibull_c$aic, ajuste_gamma_c$aic, ajuste_lognormal_c$aic, ajuste_normal_c$aic)  
)  
aic_values_c
```

	Distribuição	AIC
1	Weibull	269.7264
2	Gamma	269.8562
3	Lognormal	265.9106
4	Normal	308.5494

Interpretação:

A distribuição Lognormal apresenta o menor AIC, indicando o melhor ajuste.

5.4.5 Teste de Kolmogorov-Smirnov

```
ks.test(dados_c, "plnorm", meanlog=ajuste_lognormal_c$estimate["meanlog"], sdlog=ajuste_lognormal_c$estimate["sdlog"])
```

Exact one-sample Kolmogorov-Smirnov test


```
data: dados_c  
D = 0.10729, p-value = 0.8441  
alternative hypothesis: two-sided
```

Interpretação:

O p-valor é maior que 0,05, não rejeitando a hipótese de aderência à distribuição Lognormal.

5.4.6 Plotagem do Histograma com a Curva Ajustada

```
hist(dados_c, breaks=10, freq=FALSE, col="lightcoral", main="Ajuste da Distribuição Lognormal",  
curve(dlnorm(x, meanlog=ajuste_lognormal_c$estimate["meanlog"], sdlog=ajuste_lognormal_c$est.  
col="purple", lwd=2, add=TRUE)  
legend("topright", legend="Distribuição Lognormal", col="purple", lwd=2)
```



5.5 d) Conjunto de dados (d)

5.5.1 Dados


```
dados_d <- c(4.391658, 5.364267, 10.707930, 5.431008, 6.904122, 6.960462, 12.741468, 8.0  
8.434530, 9.747057, 6.440681, 7.623020, 9.276933, 8.711818, 5.250229, 6.4  
9.717008, 9.317296, 9.011653, 11.758927, 10.844472, 9.644711, 7.541715, 7.5  
9.654606, 6.222452, 5.207637)
```

5.5.2 Análise Descritiva

```
summary(dados_d)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
3.478	6.451	7.859	7.994	9.652	12.741

```
hist(dados_d, breaks=10, col="lightyellow", main="Histograma dos Dados (d)", xlab="Valores")
```



5.5.3 Ajuste das Distribuições

```
ajuste_weibull_d <- fitdist(dados_d, "weibull")  
ajuste_gamma_d <- fitdist(dados_d, "gamma")  
ajuste_lognormal_d <- fitdist(dados_d, "lnorm")  
ajuste_normal_d <- fitdist(dados_d, "norm")
```

5.5.4 Comparação dos Critérios de Informação (AIC)

```
aic_values_d <- data.frame(
  Distribuição = c("Weibull", "Gamma", "Lognormal", "Normal"),
  AIC = c(ajuste_weibull_d$aic, ajuste_gamma_d$aic, ajuste_lognormal_d$aic, ajuste_normal_d$aic)
)
aic_values_d
```

	Distribuição	AIC
1	Weibull	136.3711
2	Gamma	137.5245
3	Lognormal	139.0259
4	Normal	136.6819

Interpretação:

A distribuição Weibull apresenta o menor AIC (136.37110), indicando o melhor ajuste aos dados.

5.5.5 Teste de Kolmogorov-Smirnov para a Distribuição Weibull

```
ks.test(dados_d, "pweibull", shape=ajuste_weibull_d$estimate["shape"], scale=ajuste_weibull_d$estimate["scale"])
```

Exact one-sample Kolmogorov-Smirnov test


```
data: dados_d
D = 0.074926, p-value = 0.9913
alternative hypothesis: two-sided
```

Interpretação:

- O p-valor é maior que 0,05, não rejeitando a hipótese de que os dados seguem uma distribuição Weibull.
- Portanto, para o conjunto de dados (d), a distribuição Weibull é a que melhor se ajusta.

5.5.6 Plotagem do Histograma com a Curva Ajustada

```
hist(dados_d, breaks=10, freq=FALSE, col="lightyellow", main="Ajuste da Distribuição Weibull")
curve(dweibull(x, shape=ajuste_weibull_d$estimate["shape"], scale=ajuste_weibull_d$estimate["scale"],
              col="blue", lwd=2, add=TRUE))
legend("topright", legend="Distribuição Weibull", col="blue", lwd=2)
```



5.6 e) Conjunto de dados (e)

5.6.1 Dados


```
dados_e <- c(3.816942, 4.123619, 4.575150, 3.214129, 4.854917, 3.647232, 4.003734, 3.261923)
```

5.6.2 Análise Descritiva

```
summary(dados_e)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
3.214	3.551	3.910	3.937	4.237	4.855

```
hist(dados_e, breaks=10, col="lightgray", main="Histograma dos Dados (e)", xlab="Valores")
```



5.6.3 Ajuste das Distribuições

```
ajuste_weibull_e <- fitdist(dados_e, "weibull")
ajuste_gamma_e <- fitdist(dados_e, "gamma")
ajuste_lognormal_e <- fitdist(dados_e, "lnorm")
ajuste_normal_e <- fitdist(dados_e, "norm")
```

5.6.4 Comparação dos Critérios de Informação (AIC)

```
aic_values_e <- data.frame(
  Distribuição = c("Weibull", "Gamma", "Lognormal", "Normal"),
  AIC = c(ajuste_weibull_e$aic, ajuste_gamma_e$aic, ajuste_lognormal_e$aic, ajuste_normal_e$aic)
)
aic_values_e
```

	Distribuição	AIC
1	Weibull	17.48481
2	Gamma	16.78578
3	Lognormal	16.74810
4	Normal	16.95620

Interpretação:

A distribuição Lognormal apresenta o menor AIC (16.74810), indicando o melhor ajuste aos dados.

5.6.5 Teste de Kolmogorov-Smirnov para a Distribuição Lognormal

```
ks.test(dados_e, "plnorm", meanlog=ajuste_lognormal_e$estimate["meanlog"], sdlog=ajuste_lognormal_e$estimate["sdlog"])
```

Exact one-sample Kolmogorov-Smirnov test

```
data: dados_e
D = 0.15288, p-value = 0.9774
alternative hypothesis: two-sided
```

Interpretação:

- O p-valor é maior que 0,05, não rejeitando a hipótese de que os dados seguem uma distribuição Lognormal.
- Portanto, para o conjunto de dados (e), a distribuição Lognormal é a que melhor se ajusta.

5.6.6 Plotagem do Histograma com a Curva Ajustada

```
hist(dados_e, breaks=10, freq=FALSE, col="lightgray", main="Ajuste da Distribuição Lognormal", las=1)
curve(dlnorm(x, meanlog=ajuste_lognormal_e$estimate["meanlog"], sdlog=ajuste_lognormal_e$estimate["sdlog"],
            col="purple", lwd=2, add=TRUE))
legend("topright", legend="Distribuição Lognormal", col="purple", lwd=2)
```

Ajuste da Distribuição Lognormal

